PEDRO LIMA DE ASSUNÇÃO FILHO

RECONHECIMENTO DAS PALAVRAS DIREITA E ESQUERDA COM REDE DE FUNÇÃO DE BASE RADIAL (RBF)

Relatório apresentado à disciplina Redes Neurais, ministrada pelo Prof. Dr. Areolino de Almeida Neto, sobre o trabalho de reconhecimento de fonemas via rede de Kohonen ou RBF.

11 de novembro de 2026

1 RESUMO

Este trabalho treina uma **rede de função de base radial (RBF)** para reconhecer as sílabas DI, REI, TA, ES, QUER e DA das palavras DIREITA e ESQUERDA e, a partir delas, as palavras inteiras. A rede segue o algoritmo da aula: os dados de entrada são normalizados, os centros dos neurônios escondidos são achados pelo algoritmo **WTA**, as aberturas são calculadas pelas regras do slide, centros e aberturas são congelados e os pesos da saída são treinados pela **regra delta**, como na MLP. Tudo foi escrito à mão em MATLAB/Octave, sem nenhuma função pronta de rede neural. As amostras foram divididas em **75% para treino, 15% para validação e 10% para teste**, como pede o enunciado.

Cada parâmetro foi escolhido por teste, num total de **305 redes treinadas**, variando uma coisa por vez. A rede escolhida tem **200 neurônios escondidos**. Nas 14 palavras de teste, nunca usadas em nenhuma escolha, ela reconheceu **12 (85,7%), sem nenhuma troca entre direita e esquerda**, e **13 de 14 (92,9%)** na fala contínua. Na validação cruzada com 127 palavras, reconheceu **85,0%**.

Os testes mostraram que a **abertura** dos neurônios é o parâmetro mais sensível da RBF, que a regra delta só converge abaixo de um **limite de taxa de aprendizado** que pode ser calculado, e que a RBF chega ao mesmo nível da MLP do primeiro trabalho.

2 DADOS: SEGMENTAÇÃO E ENTRADA DA REDE

A preparação dos dados é a mesma do primeiro trabalho (MLP). As duas gravações do professor (68 repetições de "direita" e 73 de "esquerda") foram cortadas por script, sem corte manual. O volume do som é medido em pedaços de 20 ms (FFT); onde ele passa de um limiar há uma palavra, e dentro da palavra as sílabas são cortadas nos **vales** do volume, onde a boca fecha numa consoante (Figura 1). Também foram recortados 114 trechos de silêncio, a 7ª classe.

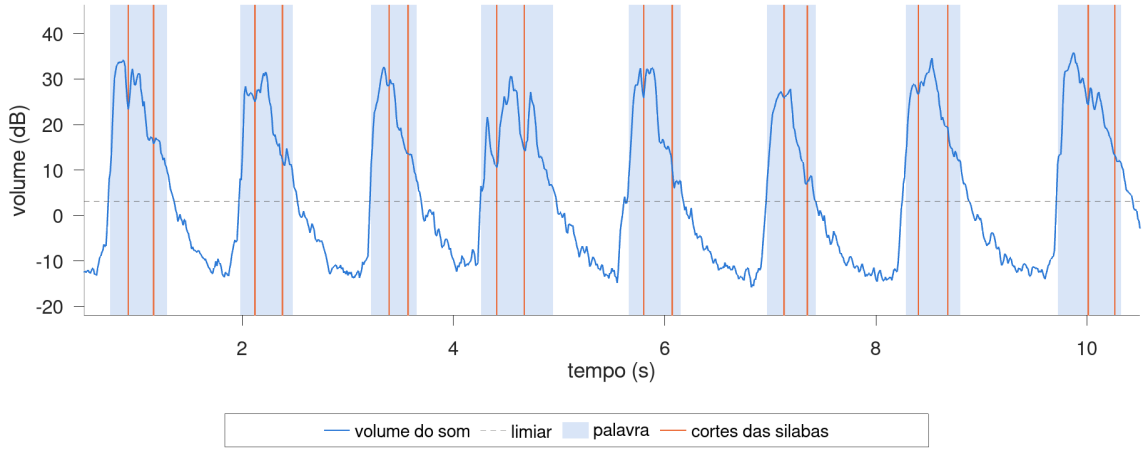


Figura 1 – Primeiros 10 s da gravação "direita": volume do som (azul), palavras encontradas (faixas claras), limiar (tracejado) e os cortes das sílabas (laranja).

Entrada da rede. O áudio é percorrido por uma janela de 150 ms que anda 25 ms por vez. A FFT de cada janela, de 0 a 5 kHz, é dividida em **32 faixas de 156 Hz**, e cada faixa vira a média das amplitudes naquele grupo de frequências, como explicado em aula. Junto com a janela atual entram as janelas 50 e 100 ms antes e depois (o **contexto**), o que dá **160 entradas**. Cada janela recebe como rótulo a sílaba onde cai o seu centro.

Divisão. A divisão é feita por repetição da palavra (todas as janelas de uma repetição vão para o mesmo conjunto), na proporção pedida no enunciado:

Tabela 1 – Divisão das amostras (75% / 15% / 10%)

Conjunto	direita	esquerda	silêncios	Janelas
Treino (75%)	51	55	86	2.963
Validação (15%)	10	11	17	590
Teste (10%)	7	7	11	408

3 A REDE RBF

3.1 Estrutura

A RBF tem uma única camada escondida, como diz o slide 6. Cada neurônio escondido *i* tem um **centro** c_i (um vetor de 160 números, um "exemplo típico" de janela) e um **raio** σ_i. Ele mede a distância euclidiana da entrada até o seu centro e responde com uma gaussiana:

$$\text{out}_i = \exp\left(-\|x - c_i\|^2 / (2\,\sigma_i^2) \right)$$

A resposta vale 1 quando a entrada está em cima do centro e cai para perto de 0 quando ela se afasta; o raio decide o quão rápido ela cai. Cada neurônio de saída (um por classe) faz a soma ponderada das respostas dos neurônios escondidos, mais o bias, e passa por uma sigmoide. A classe reconhecida é a saída

de maior valor. A rede final é **160 entradas → 200 neurônios gaussianos → 7 saídas**.

3.2 Treinamento

O treinamento segue os cinco passos do slide 14 (arquivo *rbf.m*):

- **1) Normalização da entrada.** Foram testadas as duas do slide 9, $(x - x_{mín})/(x_{máx} - x_{mín})$ para [0, 1] e para [−1, 1], e outras três (max, db e zscore). A escolhida foi a **db** (seção 5).
- **2) Centros pelo algoritmo WTA** (slide 10). Os centros começam em janelas de treino sorteadas. Para cada janela x, só o centro mais perto (o vencedor) anda na direção dela: $c_i = c_i + \eta \cdot (x - c_i)$. Isso se repete enquanto o erro de quantização E_q (a distância média, ao quadrado, de cada janela ao seu centro mais perto, slide 11) ainda cai mais de 0,1% por passada.
- **3) Aberturas** (slide 12). Foram testadas as três regras: raio único $\sigma = k \cdot d_{máx}$; metade da distância ao centro mais perto; média das distâncias aos T centros mais perto. A escolhida foi o **raio único com k = 0,5**.
- **4) Centros e aberturas são congelados.**
- **5) Pesos da saída pela regra delta**, igual ao treino da MLP (slide 13): $\Delta W = \eta \cdot e \cdot f' \cdot out$, com e = saída desejada − saída da rede, $f' = y(1 - y)$ (derivada da sigmoide) e out = saída dos neurônios escondidos. Os pesos são atualizados em lotes de 32 janelas, com momento 0,9 (como na MLP), e o treino para quando o erro na validação não melhora por 200 épocas.

3.3 Limite da taxa de aprendizado

O slide 15 diz que taxas altas aceleram o aprendizado e taxas baixas evitam oscilações. Na RBF, esse limite pode ser calculado: como os centros e as aberturas estão congelados, a regra delta só converge se a taxa for menor que $2 \div \lambda_{máx}$, onde $\lambda_{máx}$ é o maior autovalor de $\Phi^T \cdot \Phi / n$ (Φ é a saída dos neurônios escondidos para as n janelas de treino). Na rede escolhida, $\lambda_{máx} = 85{,}6$, então a regra delta com saída linear só converge com **$\eta < 0{,}023$**. A Figura 2 mostra o que acontece em cada caso:

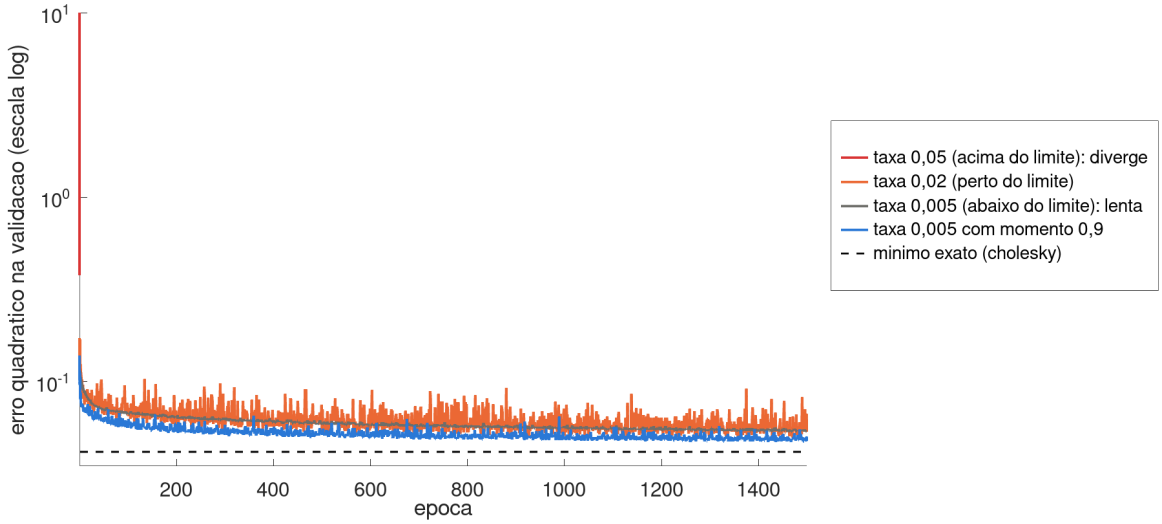


Figura 2 – Erro na validação a cada época da regra delta (saída linear), com a mesma camada escondida. Acima do limite (0,05) os pesos explodem na 1ª época; perto dele (0,02) o erro oscila; abaixo (0,005) desce devagar; com momento 0,9 desce mais rápido. A linha tracejada é o menor erro possível.

4 PROGRAMA DE RECONHECIMENTO DAS PALAVRAS

O programa de reconhecimento é o mesmo do primeiro trabalho: ele passa a janela de 150 ms pelo áudio e, a cada 25 ms, pergunta à rede qual é a sílaba. Uma **máquina de estados** espera "di" (ou "es"), depois "rei" (ou "quer") e depois "ta" (ou "da"), e só então reconhece a palavra. Uma sílaba fora da ordem faz a palavra ser abandonada. Como uma sílaba falada ocupa de 6 a 10 janelas, o programa ignora até **2 janelas seguidas fora da ordem** (erros isolados da rede) antes de abandonar a palavra; uma sílaba trocada de verdade continua reprovada.

5 COMO A REDE FOI ESCOLHIDA

5.1 Procedimento

Cada parâmetro foi escolhido por teste, uma etapa por vez, na ordem do algoritmo da aula; o vencedor de cada etapa segue para a próxima. Cada opção foi treinada **5 vezes** (sorteios diferentes dos centros iniciais e da ordem das amostras), e comparamos a média e o desvio. Tudo foi medido na validação (21 palavras), já com a tolerância de 2 janelas; o teste ficou guardado para o final. O critério principal foi o número de **palavras** reconhecidas; em caso de empate, decidiu o acerto das sílabas e, depois, a opção mais simples. Ao todo foram **305 redes treinadas**.

Nas etapas 1 a 5, os pesos da saída foram calculados direto por mínimos quadrados (a solução exata do mesmo erro que a regra delta minimiza). O motivo é o limite da seção 3.3: ele muda a cada configuração, e com uma taxa fixa a regra delta

poderia divergir numa opção e não em outra, fazendo uma camada escondida boa parecer ruim. Assim, cada etapa compara só a camada escondida. A regra delta foi ajustada na etapa 6.

5.2 Resultado de cada etapa

Tabela 2 – Resultado de cada etapa (validação, média de 5 treinos, tolerância de 2 janelas; 21 palavras)

Etapa	Opção	Palavras	Sílabas
1. Entrada	**32 faixas, com contexto (160 entradas)**	**76,2%**	**72,4%**
	32 faixas, sem contexto (32 entradas)	72,4%	62,6%
	64 faixas, sem contexto (64 entradas)	72,4%	61,0%
	64 faixas, com contexto (320 entradas)	70,5%	70,9%
2. Normalização	**db**	**78,1%**	**82,6%**
	zscore	77,1%	69,3%
	min-max [0, 1] (slide 9)	76,2%	72,4%
	min-max [−1, 1] (slide 9)	76,2%	72,4%
	max	74,3%	73,7%
3. Neurônios escondidos	400	86,7%	83,2%
	200	**83,8%**	**83,2%**
	800	83,8%	82,8%
	50 / 100 / 25	80,0 / 78,1 / 78,1%	80,6 / 82,6 / 73,6%
4. Centros	**WTA, η = 0,05**	**83,8%**	**83,2%**
	WTA, η = 0,1 / 0,3	81,9 / 81,0%	83,0 / 83,0%
	k-means (comparação)	81,0%	82,8%
	WTA, η = 0,01	77,1%	82,7%
5. Abertura	**raio único, k = 0,5**	**84,8%**	**82,7%**
	raio único, k = 0,3 / 1	83,8 / 82,9%	83,2 / 81,5%
	média dos T = 2 / 3 / 5 mais perto	79,0 / 79,0 / 78,1%	83,4 / 83,3 / 83,3%
	raio único, k = 0,1 / 0,2	79,0 / 78,1%	79,8 / 83,3%
	metade da distância ao mais perto	74,3%	76,8%
6. Pesos da saída	**delta sigmoide, η = 0,1, momento 0,9**	**81,0%**	**80,0%**
	delta linear, η = 0,02, momento 0,9	81,9%	78,7%
	delta linear, η = 0,005 a 0,01, momento 0,9	80,0%	78,5 a 78,9%
	delta sem momento (até 1.000 épocas)	68,6 a 79,0%	73,3 a 77,4%
	delta linear, η = 0,05 (acima do limite)	0% (divergiu)	13,3%
	mínimos quadrados (comparação)	84,8%	82,7%

- **Entrada:** o contexto ganhou 10 pontos nas sílabas, pelo mesmo motivo da MLP: ele separa sílabas com a mesma vogal, como "es" e "quer".

- **Normalização:** as cinco empataram nas palavras e a db ganhou nas sílabas por 10 pontos. As duas normalizações do slide deram resultados idênticos: passar de [0, 1] para [−1, 1] dobra todas as distâncias, e o raio $\sigma = k \cdot d_{máx}$ dobra junto, então cada gaussiana responde igual.
- **Neurônios:** 200, 400 e 800 empataram; 200 é o mais simples. Como o melhor resultado ficou na ponta da faixa testada (400), a etapa foi refeita com 800 para conferir: não melhora e treina 14 vezes mais devagar.
- **Centros:** o WTA empatou com o k-means. Com $\eta = 0{,}01$ os centros andam devagar demais; com $\eta = 0{,}3$ o resultado varia mais entre os treinos.
- **Abertura:** foi o parâmetro mais sensível. A regra da metade da distância deixa as gaussianas estreitas demais, e cada neurônio só responde a janelas quase em cima do centro.
- **Pesos da saída:** sem momento, a regra delta ainda estava aprendendo no limite de 1.000 épocas; com momento 0,9 ela converge. A melhor foi a sigmoide com $\eta = 0{,}1$, que usa exatamente a fórmula do slide 13. Os mínimos quadrados, que não estão nos slides, ficam só como comparação: a regra delta empata com eles nas palavras.

6 VALIDAÇÃO CRUZADA

Com 21 palavras de validação, cada palavra vale quase 5 pontos. Para ter um número mais confiável, as 127 palavras que não são de teste foram divididas em 5 partes, e a rede escolhida foi treinada 5 vezes, cada vez validando numa parte diferente. Assim, cada uma das 127 palavras foi reconhecida por uma rede que nunca a viu.

Tabela 3 – Validação cruzada: palavras reconhecidas das 127

Tolerância do programa 2	Palavras	Sílabas
nenhuma	101 (79,5%)	86,7%
1 janela	105 (82,7%)	86,7%
2 janelas (usada)	**108 (85,0%)**	**86,7%**
3 janelas	110 (86,6%)	86,7%

A tolerância acrescentou 7 palavras. Por sílaba, o acerto foi: di 85%, rei 91%, ta 83%, es 77%, quer 89% e da 96%. Como na MLP, o "es" é a sílaba mais difícil, porque o começo dele é a mesma vogal do "quer".

7 RESULTADO FINAL

A rede escolhida foi treinada 5 vezes; ficou a que reconheceu mais palavras na validação (as cinco empataram em 17 de 21, e o desempate foi pelo acerto das janelas). Só depois as 14 palavras de teste foram usadas, uma única vez.

Tabela 4 – Resultado no teste

Medida	Resultado
Palavras isoladas	**12 de 14 (85,7%)**: direita 7/7, esquerda 5/7, nenhuma trocada
Média dos 5 treinos	12,6 de 14 (90,0%); todos entre 12 e 13 palavras
Fala contínua	**13 de 14 (92,9%)**: 0 trocadas, 0 falsos alarmes
Janelas	treino 91,8% / validação 84,2% / teste 89,0%
Sílabas (teste)	87,1%

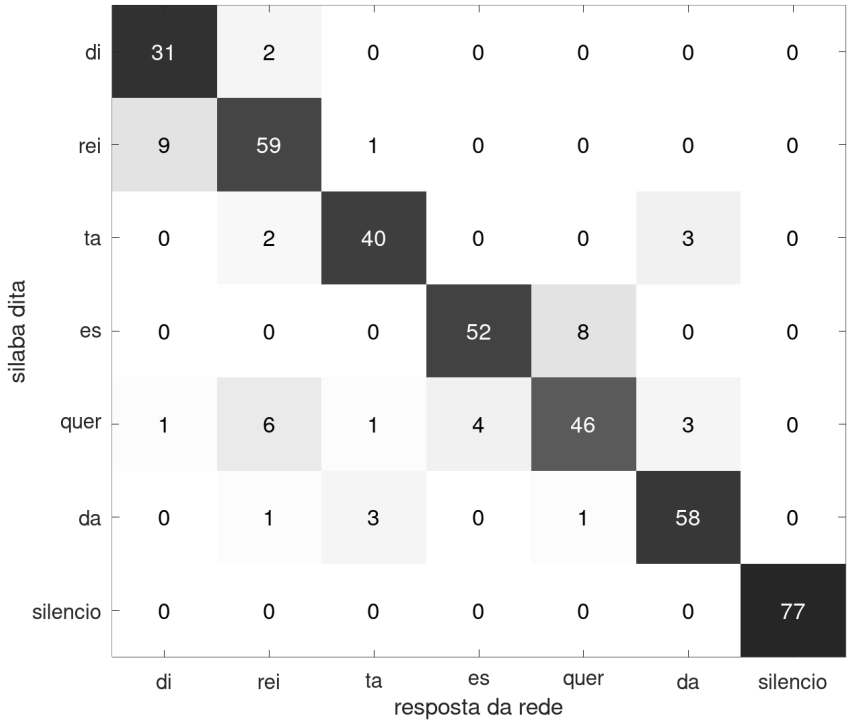


Figura 3 – Matriz de confusão das janelas de teste (linha: sílaba dita; coluna: resposta da rede).

As trocas mais comuns são entre sílabas vizinhas da mesma palavra ("rei" respondido como "di", "quer" como "es" ou "rei"). Como esses erros aparecem em janelas soltas, a máquina de estados com tolerância não os transforma em palavras trocadas.

8 COMPARAÇÃO COM A MLP

As duas redes usam as mesmas janelas, a mesma entrada (32 faixas com contexto) e o mesmo programa de reconhecimento. As divisões são diferentes (a MLP usou 60/20/20; a RBF, 75/15/10, como pede este enunciado), então os testes não são as mesmas palavras.

Tabela 5 – MLP (primeiro trabalho) e RBF

Medida	**MLP**	**RBF**
Estrutura	160 → 64 → 32 → 7	160 → 200 gaussianas → 7
Treino	retropropagação em todas as camadas	WTA nos centros; regra delta na saída
Validação cruzada, sem tolerância	80,4%	79,5%
Validação cruzada, tolerância 2	91,1%	85,0%
Sílabas (validação cruzada)	87,1%	86,7%
Palavras de teste	24/29 (82,8%)	12/14 (85,7%)
Fala contínua (teste)	27/29 (93,1%)	13/14 (92,9%)
Trocas direita ↔ esquerda	0	0

Sem tolerância e nas sílabas, as duas redes empatam. Com a tolerância, a MLP reconhece mais palavras na validação cruzada, e no teste a RBF fica um pouco à frente, mas com só 14 palavras essa diferença não é conclusiva. A RBF precisou de mais neurônios (200 contra 64 e 32) porque cada neurônio dela responde só a uma região em torno do seu centro, enquanto um neurônio da MLP divide o espaço de entrada inteiro.

9 CONCLUSÃO

A rede RBF, treinada como na aula, reconheceu **85,7% das palavras de teste e 92,9% da fala contínua**, sem nunca trocar DIREITA por ESQUERDA, e **85,0%** das 127 palavras na validação cruzada. Os principais achados foram:

- **A abertura é o parâmetro mais sensível da RBF.** Com o raio certo ($\sigma = 0{,}5 \cdot d_{máx}$) a rede chega a 85% das palavras; com gaussianas estreitas demais (metade da distância) cai para 74%.
- **A taxa da regra delta tem um limite que pode ser calculado.** Com centros e aberturas congelados, a regra delta só converge com $\eta < 2 \div \lambda_{máx}$. O que aconteceu nos testes confere com essa conta: acima do limite os pesos explodiram, perto dele o erro oscilou e abaixo convergiu.
- **O momento faz a regra delta convergir.** Sem ele, a regra delta ainda aprendia depois de 1.000 épocas; com momento 0,9, igual à MLP, ela converge e empata nas palavras com a solução exata de mínimos quadrados.

- **Mais neurônios ajudam até um ponto.** De 25 para 200 neurônios a rede melhora; acima disso não ganha nada e treina muito mais devagar.
- **O contexto e a normalização db também valem para a RBF:** o contexto separa sílabas com a mesma vogal, e as duas normalizações min-max do slide são equivalentes para a RBF.
- **RBF e MLP chegam ao mesmo nível** sem tolerância e nas sílabas; com a tolerância, a MLP reconhece um pouco mais de palavras.

A principal limitação, como na MLP, é a separação entre "es" e "quer", que têm a mesma vogal. Como o teste tem só 14 palavras, a validação cruzada é a medida mais confiável do desempenho.

APÊNDICE – ARQUIVOS DO PROJETO

O projeto roda com um único comando, **rodar_projeto('rbf')**, no MATLAB ou no Octave; no Windows, também com dois cliques em **rodar_projeto.bat** (opção 3). As instruções completas estão no arquivo COMO_RODAR.txt.

Tabela 6 – Arquivos usados pela rede RBF

Arquivo	**O que faz**
segmentacao/segmentar_audios.m	corta as gravações em palavras, sílabas e silêncios
rede/extrair_entradas.m	transforma cada janela de áudio no vetor de entrada (salvo em .mat)
rede/entrada.m	FFT em faixas, janelas vizinhas e normalização (inclusive min-max)
rede_rbf/rbf.m	a rede RBF: WTA, aberturas, gaussiana, regra delta e divisão 75/15/10
rede_rbf/treinar_rbf.m	programa de treino: treina a rede final e mede o teste
rede/programa2_reconhecer.m	programa de reconhecimento das palavras (máquina de estados)
rede_rbf/experimentos_rbf.m	testes usados para escolher cada parâmetro e validação cruzada