PEDRO LIMA DE ASSUNÇÃO FILHO

RECONHECIMENTO DAS PALAVRAS DIREITA E ESQUERDA COM REDE DE FUNÇÃO DE BASE RADIAL (RBF)

Relatório apresentado à disciplina Redes Neurais, ministrada pelo Prof. Dr. Areolino de Almeida Neto, sobre o trabalho de reconhecimento de fonemas via rede de Kohonen ou RBF.

11 de novembro de 2026

1 RESUMO

Este trabalho treina uma rede de função de base radial (RBF) para reconhecer as sílabas DI, REI, TA, ES, QUER e DA das palavras DIREITA e ESQUERDA e, a partir delas, as palavras inteiras. A rede segue o algoritmo da aula: os dados de entrada são normalizados, os centros dos neurônios escondidos são achados pelo algoritmo WTA, as aberturas são calculadas pelas regras do slide, centros e aberturas são congelados e os pesos da saída são treinados pela regra delta, como na MLP. Tudo foi escrito à mão em MATLAB/Octave, sem nenhuma função pronta de rede neural. As amostras foram divididas em 75% para treino, 15% para validação e 10% para teste, como pede o enunciado.

Cada parâmetro foi escolhido por teste, num total de 305 redes treinadas, variando uma coisa por vez. A rede escolhida tem 200 neurônios escondidos. Nas 14 palavras de teste, nunca usadas em nenhuma escolha, ela reconheceu **12 palavras (85,7%) e 13 de 14 (92,9%) na fala contínua**, sem nenhuma troca entre direita e esquerda. Na validação cruzada com 127 palavras, reconheceu 85,0%.

Os testes mostraram que a abertura dos neurônios é o parâmetro mais sensível da RBF, que a regra delta só converge abaixo de um limite de taxa de aprendizado que pode ser calculado, e que a RBF empata com a MLP do primeiro trabalho nas sílabas, mas reconhece um pouco menos palavras inteiras.

2 DADOS: SEGMENTAÇÃO E ENTRADA DA REDE

A preparação dos dados é a mesma do primeiro trabalho (MLP). As duas gravações do professor (68 repetições de "direita" e 73 de "esquerda") foram cortadas por script, sem corte manual. O volume do som é medido em pedaços de 20 ms (FFT); onde ele passa de um limiar há uma palavra, e dentro da palavra as sílabas são cortadas nos vales do volume, onde a boca fecha numa consoante (Figura 1). Também foram recortados 114 trechos de silêncio, a 7ª classe.

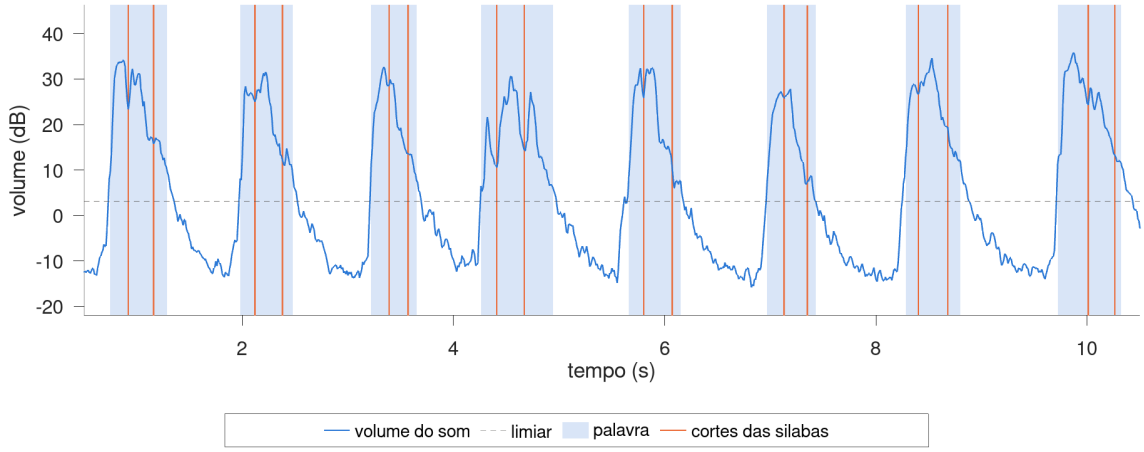


Figura 1 – Primeiros 10 s da gravação "direita": volume do som (azul), palavras encontradas (faixas claras), limiar (tracejado) e os cortes das sílabas (laranja).

Entrada da rede. O áudio é percorrido por uma janela de 150 ms que anda 25 ms por vez. A FFT de cada janela, de 0 a 5 kHz, é dividida em 32 faixas de 156 Hz, e cada faixa vira a média das amplitudes naquele grupo de frequências, como explicado em aula. Junto com a janela atual entram as janelas 50 e 100 ms antes e depois (o contexto), o que dá 160 entradas. Cada janela recebe como rótulo a sílaba onde cai o seu centro.

Divisão. A divisão é feita por repetição da palavra (todas as janelas de uma repetição vão para o mesmo conjunto), na proporção pedida no enunciado:

Tabela 1 – Divisão das amostras (75% / 15% / 10%)

Conjunto	direita	esquerda	silêncios	Janelas
Treino (75%)	51	55	86	2.963
Validação (15%)	10	11	17	590
Teste (10%)	7	7	11	408

3 A REDE RBF

3.1 Estrutura

A RBF tem uma única camada escondida, como diz o slide 6. Cada neurônio escondido *i* tem um centro c_i (um vetor de 160 números, um "exemplo típico" de janela) e um raio σ_i. Ele mede a distância euclidiana da entrada até o seu centro e responde com uma gaussiana:

$$\text{out}_i = \exp\left(-\|x - c_i\|^2 / (2\,\sigma_i^2) \right)$$

A resposta vale 1 quando a entrada está em cima do centro e cai para perto de 0 quando ela se afasta; o raio decide o quão rápido ela cai. Cada neurônio de saída (um por classe) faz a soma ponderada das respostas dos neurônios escondidos, mais o bias, e passa por uma sigmoide. A classe reconhecida é a saída

de maior valor. A rede final é 160 entradas → 200 neurônios gaussianos → 7 saídas.

3.2 Treinamento

O treinamento segue os cinco passos do slide 14 (arquivo *rbf.m*):

- **1) Normalização da entrada.** Foram testadas as duas do slide 9, $(x - x_{mín})/(x_{máx} - x_{mín})$ para [0, 1] e para [−1, 1], e outras três (max, db e zscore). A escolhida foi a db (seção 5).
- **2) Centros pelo algoritmo WTA** (slide 10). Os centros começam em janelas de treino sorteadas. Para cada janela x, só o centro mais perto (o vencedor) anda na direção dela: $c_i = c_i + \eta \cdot (x - c_i)$. Isso se repete enquanto o erro de quantização E_q (a distância média, ao quadrado, de cada janela ao seu centro mais perto, slide 11) ainda cai mais de 0,1% por passada.
- **3) Aberturas** (slide 12). Foram testadas as três regras: raio único $\sigma = k \cdot d_{máx}$; metade da distância ao centro mais perto; média das distâncias aos T centros mais perto. A escolhida foi o raio único com k = 0,5.
- **4) Centros e aberturas são congelados.**
- **5) Pesos da saída pela regra delta**, igual ao treino da MLP (slide 13): $\Delta W = \eta \cdot e \cdot f' \cdot out$, com e = saída desejada − saída da rede, $f' = y(1 - y)$ (derivada da sigmoide) e out = saída dos neurônios escondidos. Os pesos são atualizados em lotes de 32 janelas, com momento 0,9 (como na MLP), e o treino para quando o erro na validação não melhora por 200 épocas.

3.3 Limite da taxa de aprendizado

O slide 15 diz que taxas altas aceleram o aprendizado e taxas baixas evitam oscilações. Na RBF, esse limite pode ser calculado: como os centros e as aberturas estão congelados, a regra delta só converge se a taxa for menor que $2 \div \lambda_{máx}$, onde $\lambda_{máx}$ é o maior autovalor de $\Phi^T \cdot \Phi / n$ (Φ é a saída dos neurônios escondidos para as n janelas de treino). Na rede escolhida, $\lambda_{máx} = 85{,}6$, então a regra delta com saída linear só converge com $\eta < 0{,}023$. A Figura 2 mostra o que acontece em cada caso:

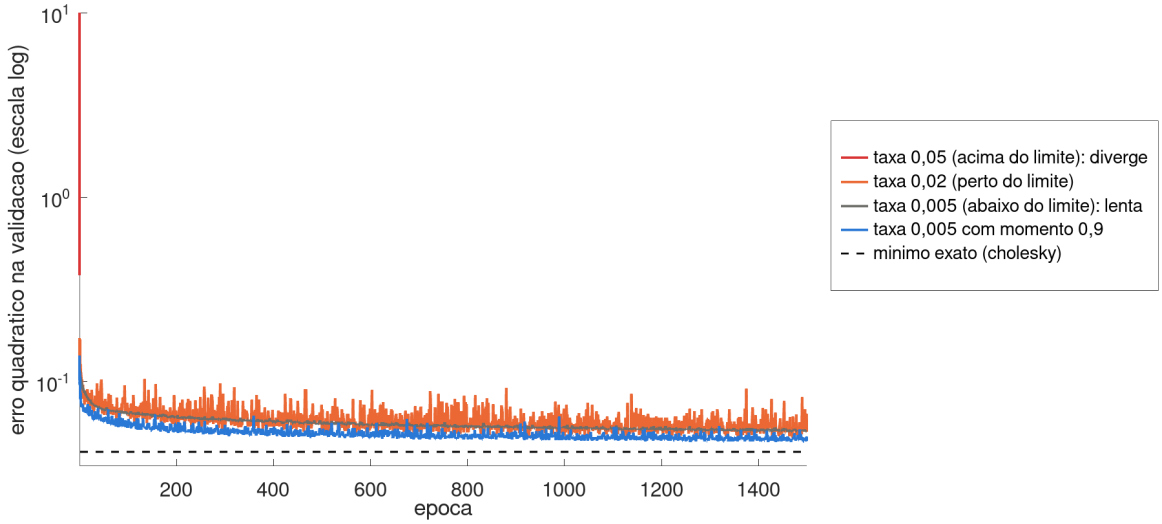


Figura 2 – Erro na validação a cada época da regra delta (saída linear), com a mesma camada escondida. Acima do limite (0,05) os pesos explodem na 1ª época; perto dele (0,02) o erro oscila; abaixo (0,005) desce devagar; com momento 0,9 desce mais rápido. A linha tracejada é o menor erro possível.

4 PROGRAMA DE RECONHECIMENTO DAS PALAVRAS

O programa de reconhecimento é o mesmo do primeiro trabalho: ele passa a janela de 150 ms pelo áudio e, a cada 25 ms, pergunta à rede qual é a sílaba. Uma máquina de estados espera "di" (ou "es"), depois "rei" (ou "quer") e depois "ta" (ou "da"), e só então reconhece a palavra. Uma sílaba fora da ordem faz a palavra ser abandonada. Como uma sílaba falada ocupa de 6 a 10 janelas, o programa ignora até 2 janelas seguidas fora da ordem (erros isolados da rede) antes de abandonar a palavra; uma sílaba trocada de verdade continua reprovada.

5 COMO A REDE FOI ESCOLHIDA

5.1 Procedimento

Cada parâmetro foi escolhido por teste, uma etapa por vez, na ordem do algoritmo da aula; o vencedor de cada etapa segue para a próxima. Cada opção foi treinada 5 vezes (sorteios diferentes dos centros iniciais e da ordem das amostras), e comparamos a média e o desvio. Tudo foi medido na validação (21 palavras), já com a tolerância de 2 janelas; o teste ficou guardado para o final. O critério principal foi o número de palavras reconhecidas; em caso de empate, decidiu o acerto das sílabas e, depois, a opção mais simples. Ao todo foram 305 redes treinadas.

Nas etapas 1 a 5, os pesos da saída foram calculados direto por mínimos quadrados (a solução exata do mesmo erro que a regra delta minimiza). O motivo é o limite da seção 3.3: ele muda a cada configuração, e com uma taxa fixa a regra delta

poderia divergir numa opção e não em outra, fazendo uma camada escondida boa parecer ruim. Assim, cada etapa compara só a camada escondida. A regra delta foi ajustada na etapa 6.

5.2 Resultado de cada etapa

Tabela 2 – Resultado de cada etapa (validação, média de 5 treinos, tolerância de 2 janelas; 21 palavras)

Etapa	Opção	Palavras	Sílabas
1. Entrada	**32 faixas, com contexto (160 entradas)**	**76,2%**	**72,4%**
	32 faixas, sem contexto (32 entradas)	72,4%	62,6%
	64 faixas, sem contexto (64 entradas)	72,4%	61,0%
	64 faixas, com contexto (320 entradas)	70,5%	70,9%
2. Normalização	**db**	**78,1%**	**82,6%**
	zscore	77,1%	69,3%
	min-max [0, 1] (slide 9)	76,2%	72,4%
	min-max [−1, 1] (slide 9)	76,2%	72,4%
	max	74,3%	73,7%
3. Neurônios escondidos	400	86,7%	83,2%
	200	**83,8%**	**83,2%**
	800	83,8%	82,8%
	50 / 100 / 25	80,0 / 78,1 / 78,1%	80,6 / 82,6 / 73,6%
4. Centros	**WTA, η = 0,05**	**83,8%**	**83,2%**
	WTA, η = 0,1 / 0,3	81,9 / 81,0%	83,0 / 83,0%
	k-means (comparação)	81,0%	82,8%
	WTA, η = 0,01	77,1%	82,7%
5. Abertura	**raio único, k = 0,5**	**84,8%**	**82,7%**
	raio único, k = 0,3 / 1	83,8 / 82,9%	83,2 / 81,5%
	média dos T = 2 / 3 / 5 mais perto	79,0 / 79,0 / 78,1%	83,4 / 83,3 / 83,3%
	raio único, k = 0,1 / 0,2	79,0 / 78,1%	79,8 / 83,3%
	metade da distância ao mais perto	74,3%	76,8%
6. Pesos da saída	**delta sigmoide, η = 0,1, momento 0,9**	**81,0%**	**80,0%**
	delta linear, η = 0,02, momento 0,9	81,9%	78,7%
	delta linear, η = 0,005 a 0,01, momento 0,9	80,0%	78,5 a 78,9%
	delta sem momento (até 1.000 épocas)	68,6 a 79,0%	73,3 a 77,4%
	delta linear, η = 0,05 (acima do limite)	0% (divergiu)	13,3%
	mínimos quadrados (comparação)	84,8%	82,7%

- *Entrada:* o contexto ganhou 10 pontos nas sílabas, pelo mesmo motivo da MLP: ele separa sílabas com a mesma vogal, como "es" e "quer".

- *Normalização:* as cinco empataram nas palavras e a db ganhou nas sílabas por 10 pontos. As duas normalizações do slide deram resultados idênticos: passar de [0, 1] para [−1, 1] dobra todas as distâncias, e o raio $\sigma = k \cdot d_{máx}$ dobra junto, então cada gaussiana responde igual.
- *Neurônios:* 200, 400 e 800 empataram; 200 é o mais simples. Como o melhor resultado ficou na ponta da faixa testada (400), a etapa foi refeita com 800 para conferir: não melhora e treina 14 vezes mais devagar.
- *Centros:* o WTA empatou com o k-means. Com $\eta = 0{,}01$ os centros andam devagar demais; com $\eta = 0{,}3$ o resultado varia mais entre os treinos.
- *Abertura:* foi o parâmetro mais sensível. A regra da metade da distância deixa as gaussianas estreitas demais, e cada neurônio só responde a janelas quase em cima do centro.
- *Pesos da saída:* sem momento, a regra delta ainda estava aprendendo no limite de 1.000 épocas; com momento 0,9 ela converge. A melhor foi a sigmoide com $\eta = 0{,}1$, que usa exatamente a fórmula do slide 13. Os mínimos quadrados, que não estão nos slides, ficam só como comparação: a regra delta empata com eles nas palavras.

6 VALIDAÇÃO CRUZADA

Com 21 palavras de validação, cada palavra vale quase 5 pontos. Para ter um número mais confiável, as 127 palavras que não são de teste foram divididas em 5 partes, e a rede escolhida foi treinada 5 vezes, cada vez validando numa parte diferente. Assim, cada uma das 127 palavras foi reconhecida por uma rede que nunca a viu.

Tabela 3 – Validação cruzada: palavras reconhecidas das 127

Tolerância do programa 2	Palavras	Sílabas
nenhuma	101 (79,5%)	86,7%
1 janela	105 (82,7%)	86,7%
2 janelas (usada)	**108 (85,0%)**	**86,7%**
3 janelas	110 (86,6%)	86,7%

A tolerância acrescentou 7 palavras. Por sílaba, o acerto foi: di 85%, rei 91%, ta 83%, es 77%, quer 89% e da 96%. Como na MLP, o "es" é a sílaba mais difícil, porque o começo dele é a mesma vogal do "quer".

7 RESULTADO FINAL

A rede escolhida foi treinada 5 vezes; ficou a que reconheceu mais palavras na validação (as cinco empataram em 17 de 21, e o desempate foi pelo acerto das janelas). Só depois as 14 palavras de teste foram usadas, uma única vez.

Tabela 4 – Resultado no teste

Medida	Resultado
Palavras isoladas	**12 de 14 (85,7%)**: direita 7/7, esquerda 5/7, nenhuma trocada
Média dos 5 treinos	12,6 de 14 (90,0%); todos entre 12 e 13 palavras
Fala contínua	**13 de 14 (92,9%)**: 0 trocadas, 0 falsos alarmes
Janelas	treino 91,8% / validação 84,2% / teste 89,0%
Sílabas (teste)	87,1%

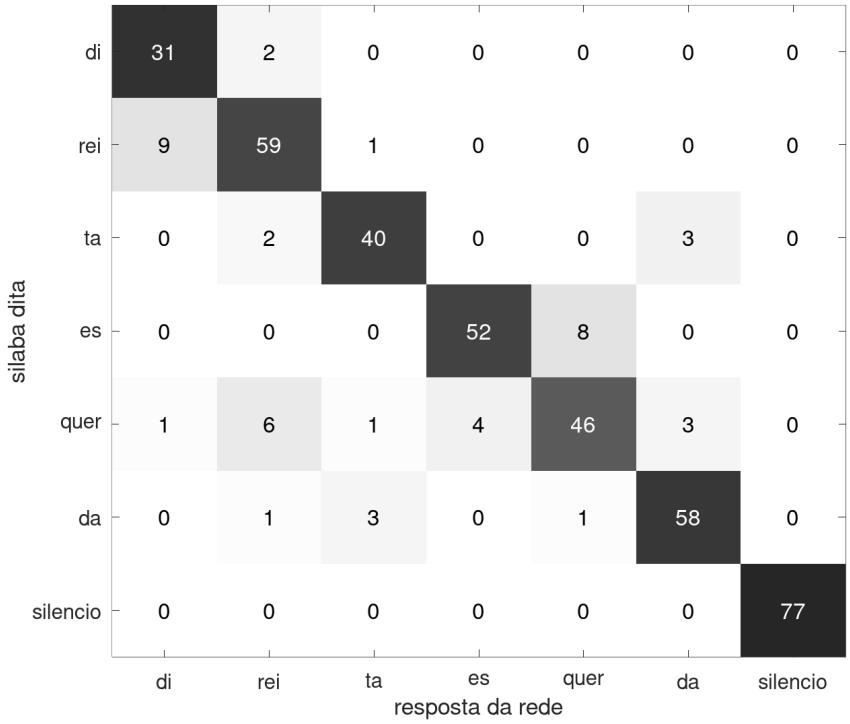


Figura 3 – Matriz de confusão das janelas de teste (linha: sílaba dita; coluna: resposta da rede).

As trocas mais comuns são entre sílabas vizinhas da mesma palavra ("rei" respondido como "di", "quer" como "es" ou "rei"). Como esses erros aparecem em janelas soltas, a máquina de estados com tolerância não os transforma em palavras trocadas.

8 COMPARAÇÃO COM A MLP

8.1 Como cada rede aprende

As duas redes recebem a mesma entrada (32 faixas com contexto, 160 números por janela) e usam o mesmo programa de reconhecimento, com a mesma tolerância. A diferença está na camada escondida e no jeito de treiná-la.

Na MLP, cada neurônio escondido faz uma soma ponderada da entrada e passa por uma sigmoide. Ele divide o espaço de entrada em dois lados e responde a entradas do espaço inteiro. Todos os pesos, das duas camadas escondidas e da saída, são ajustados juntos pela retropropagação do erro, usando os rótulos. O resultado depende dos pesos iniciais, e o treino pode parar num mínimo local.

Na RBF, cada neurônio escondido responde só às entradas perto do seu centro. O treino é feito em duas fases separadas. Na primeira, o WTA espalha os centros pelas janelas de treino sem olhar os rótulos: ele só procura onde os dados se concentram. Na segunda, só os pesos da saída são treinados com os rótulos. Por isso, dos 33.407 números da RBF, só 1.407 (201 × 7) são aprendidos pela regra delta; os outros 32.000 são as coordenadas dos centros. Como a camada escondida fica congelada, o problema da saída tem um único mínimo, e por isso foi possível calcular o limite da taxa (seção 3.3) e comparar a regra delta com a solução exata.

8.2 Resultados lado a lado

As divisões são diferentes: a MLP usou 60/20/20 e a RBF usou 75/15/10, como pede este enunciado. Por isso, as palavras de teste não são as mesmas, e a validação cruzada da MLP usou 112 palavras, contra 127 da RBF. As comparações são aproximadas, mas as duas medem a mesma coisa: palavras reconhecidas por uma rede que nunca as viu.

Tabela 5 – MLP (primeiro trabalho) e RBF

Medida	**MLP**	**RBF**
Estrutura	160 → 64 → 32 → 7	160 → 200 gaussianas → 7
Números aprendidos	12.615 pesos, todos pelo erro	32.000 dos centros (WTA) + 1.407 pesos (regra delta)
Normalização escolhida	max	db
Divisão treino / validação / teste	60 / 20 / 20%	75 / 15 / 10%
Épocas até parar	cerca de 190	cerca de 1.870 (só a saída)
Tempo de um treino	cerca de 70 s	cerca de 50 s (WTA + saída)
Variação entre os 5 treinos (validação)	85,9% ± 6,1	81,0% ± 0,0
Validação cruzada, sem tolerância	80,4% (90 de 112)	79,5% (101 de 127)
Validação cruzada, tolerância 2	91,1% (102 de 112)	85,0% (108 de 127)

Medida	MLP	RBF
Sílabas (validação cruzada)	87,1%	86,7%
Janelas de treino	95,6%	91,8%
Palavras de teste	24 de 29 (82,8%)	12 de 14 (85,7%)
Fala contínua (teste)	27 de 29 (93,1%)	13 de 14 (92,9%)
Trocas direita ↔ esquerda	0	0

Tabela 6 – Acerto de cada sílaba na validação cruzada

Rede	di	rei	ta	es	quer	da	Média
MLP	88%	86%	87%	79%	87%	96%	87,1%
RBF	85%	91%	83%	77%	89%	96%	86,7%

8.3 O que a comparação mostra

Desempenho. Sem tolerância, as duas redes reconhecem praticamente a mesma fração de palavras (80,4% e 79,5%, menos de uma palavra de diferença), e o acerto médio das sílabas também empata (87,1% e 86,7%). Olhando sílaba por sílaba, cada rede é melhor em sílabas diferentes: a RBF acerta mais "rei" e "quer", e a MLP acerta mais "di" e "ta". O "es" é a sílaba mais difícil para as duas, e o "da" a mais fácil.

Efeito da tolerância. A diferença aparece quando a tolerância é ligada: ela acrescenta 12 palavras na MLP e 7 na RBF. A tolerância só recupera palavras cujos erros são janelas soltas. Isso indica que os erros da MLP costumam ser isolados, enquanto os da RBF aparecem mais vezes em sequências de 3 ou mais janelas, que o programa não pode ignorar. Uma explicação provável é a resposta local da RBF: quando uma sílaba é falada de um jeito um pouco diferente, várias janelas seguidas caem longe dos centros certos ao mesmo tempo.

Estabilidade. A RBF variou muito menos de um treino para outro. Os 5 treinos da configuração escolhida reconheceram exatamente as mesmas 17 de 21 palavras de validação, enquanto na MLP o desvio entre os treinos foi de 6 pontos. Na RBF, o sorteio só afeta o ponto de partida do WTA, e com 200 centros os resultados acabam parecidos; na MLP, o sorteio dos pesos iniciais muda todo o caminho da retropropagação.

Tamanho e treino. A RBF precisou de mais neurônios (200 contra 64 + 32) e guarda 2,6 vezes mais números, porque cada neurônio cobre só uma região em torno do seu centro, enquanto um neurônio da MLP participa da resposta em todo o espaço. Em compensação, o treino com rótulos da RBF ajusta só 1.407 pesos: ela usa mais épocas, mas cada época é barata, e um treino completo leva um tempo parecido com o da MLP. A RBF também acerta menos as janelas de treino (91,8%

contra 95,6%), porque só a camada de saída se adapta aos rótulos.

Ajuste dos parâmetros. Na MLP, a escolha mais difícil foi a combinação de camadas com a taxa de aprendizado. Na RBF, foi a abertura, mas a taxa deixou de ser tentativa e erro, porque o seu limite pode ser calculado antes do treino.

No resultado geral, a MLP ficou um pouco à frente nas palavras inteiras, e a RBF chegou ao mesmo nível nas sílabas, com um treino mais estável e mais fácil de ajustar. No teste, a RBF aparece à frente (85,7% contra 82,8%), mas com só 14 palavras isso equivale a menos de uma palavra, e a validação cruzada é a comparação mais confiável.

9 CONCLUSÃO

O objetivo deste trabalho era reconhecer as palavras DIREITA e ESQUERDA com uma rede RBF construída à mão, seguindo o algoritmo visto em aula. A rede final, com 200 neurônios gaussianos, reconheceu 12 das 14 palavras de teste e 13 de 14 na fala contínua, sem nunca trocar uma palavra pela outra e sem falsos alarmes. Na validação cruzada, que usa 127 palavras e é a medida mais confiável, reconheceu 85,0%.

Os experimentos mostraram que, na RBF, a abertura das gaussianas importa mais que o jeito de achar os centros. O WTA e o k-means deram o mesmo resultado, e o número de centros deixou de importar a partir de 200. Já a abertura mudou o resultado em mais de 10 pontos: com gaussianas estreitas demais, cada neurônio só reconhece janelas quase idênticas ao seu centro, e a rede não generaliza; com gaussianas largas demais, todos os neurônios respondem parecido a qualquer entrada, e a rede perde a capacidade de separar as sílabas. O melhor ficou no meio, com o raio igual à metade da maior distância entre os centros.

A regra delta, usada no lugar da solução direta, também trouxe uma lição. Com a camada escondida congelada, o limite da taxa de aprendizado pode ser calculado antes do treino, e os testes confirmaram a conta: acima do limite os pesos explodem já na primeira época, perto dele o erro oscila, e abaixo ele converge. Com o momento de 0,9 usado na MLP, a regra delta chegou ao mesmo acerto de palavras da solução exata. Isso mostra que o treino da saída chegou ao seu limite, e que os erros que restam vêm da camada escondida e da própria entrada, e não do treino da saída.

Comparada com a MLP do primeiro trabalho, a RBF empata nas sílabas e sem tolerância, e fica alguns pontos atrás nas palavras quando a tolerância é usada, porque os seus erros aparecem mais em sequência. Por outro lado, ela foi muito

mais estável entre os treinos e mais previsível de ajustar. As duas redes mostram que a entrada com contexto é essencial: é ela que permite separar sílabas com a mesma vogal.

A principal limitação continua sendo a separação entre "es" e "quer", que começam com a mesma vogal. Além disso, todas as gravações são de uma única pessoa, e o conjunto de teste tem só 14 palavras. Com gravações de outras vozes, seria possível medir se a rede reconhece as palavras de qualquer pessoa, e não só desta voz.

APÊNDICE – ARQUIVOS DO PROJETO

Tudo o que a rede RBF usa fica na pasta rede_rbf, menos a segmentação, que é a mesma do primeiro trabalho. Com essa pasta aberta no MATLAB ou no Octave, o projeto roda com um único comando, rodar_projeto (ou rodar_projeto('tudo') para refazer tudo do zero); no Windows, também com dois cliques em rodar_projeto.bat, dentro da mesma pasta. As instruções completas estão no arquivo COMO_RODAR.txt.

Tabela 7 – Arquivos usados pela rede RBF

Arquivo	**O que faz**
segmentacao/segmentar_audios.m	corta as gravações em palavras, sílabas e silêncios
rede_rbf/rodar_projeto.m	confere o MATLAB/Octave e roda tudo na ordem certa
rede_rbf/extrair_entradas.m	transforma cada janela de áudio no vetor de entrada (salvo em .mat)
rede_rbf/entrada.m	FFT em faixas, janelas vizinhas e normalização (inclusive min-max)
rede_rbf/rbf.m	a rede RBF: WTA, aberturas, gaussiana, regra delta e divisão 75/15/10
rede_rbf/treinar_rbf.m	programa de treino: treina a rede final e mede o teste
rede_rbf/programa2_reconhecer.m	programa de reconhecimento das palavras (máquina de estados)
rede_rbf/experimentos_rbf.m	testes usados para escolher cada parâmetro e validação cruzada