PEDRO LIMA DE ASSUNÇÃO FILHO

RECONHECIMENTO DAS PALAVRAS DIREITA E ESQUERDA COM REDE NEURAL MLP

Relatório apresentado à disciplina Redes Neurais, ministrada pelo Prof. Dr. Areolino de Almeida Neto, sobre o trabalho de reconhecimento de fonemas via MRNA.

03 de novembro de 2026

1 RESUMO

Este trabalho desenvolve um sistema que reconhece as palavras **DIREITA** e **ESQUERDA** a partir das suas sílabas, usando uma rede neural MLP escrita à mão em MATLAB/Octave, sem nenhuma toolbox. O sistema tem duas partes. Na primeira, as gravações do professor (68 repetições de "direita" e 73 de "esquerda") são cortadas automaticamente em palavras, e cada palavra em três sílabas (di | rei | ta e es | quer | da), nos pontos em que o volume do som cai entre uma sílaba e outra. Na segunda, a rede aprende a reconhecer as 6 sílabas e o silêncio a partir das frequências do som, e um programa percorre o áudio com uma janela deslizante, pergunta à rede qual sílaba está em cada instante e só aceita a palavra quando as três sílabas aparecem na ordem certa.

Nenhum parâmetro foi escolhido "no olho". Cada opção foi treinada 5 vezes e comparada na validação, num total de **255 redes treinadas em testes automatizados**, e as dúvidas finais foram resolvidas com validação cruzada em 112 palavras. A rede escolhida é pequena: **160 entradas, camadas ocultas de 64 e 32 neurônios e sigmoide**. Nas 29 palavras de teste, que não foram usadas em nenhuma escolha, ela reconheceu **24 palavras (82,8%), sem nenhuma troca entre direita e esquerda**. Com as 29 palavras emendadas, simulando uma fala contínua, reconheceu **27 (93,1%), sem nenhum falso alarme**.

Os testes mostraram que o que mais melhora o reconhecimento é a **informação que a rede recebe**, e não o tamanho da rede: dar à rede as janelas vizinhas (contexto) foi o maior ganho do trabalho, cortar as sílabas nos vales de energia foi melhor do que dividir a palavra em partes iguais, e redes maiores não trouxeram ganho.

2 SEGMENTAÇÃO

O professor entregou duas gravações de cerca de 90 segundos: uma com 68 repetições de "direita" e outra com 73 de "esquerda". Para treinar a rede, era preciso separar cada palavra e depois cada sílaba. Tudo foi feito por script, sem nenhum corte manual.

2.1 Separar as palavras

A ideia é medir o **volume do som ao longo do tempo**. O áudio é dividido em pedaços de 20 ms e, para cada pedaço, calcula-se quanta energia ele tem (FFT, somando as frequências da voz, em decibéis). O resultado é a curva azul da Figura 1: ela sobe quando alguém fala e fica baixa no silêncio. Onde a curva passa de um limiar (15 dB acima do nível do silêncio da sala) há uma palavra. Pausas menores que 120 ms não separam palavras, e trechos menores que 200 ms são descartados como ruído. Assim foram encontradas as **68 de 68** e **73 de 73** palavras.

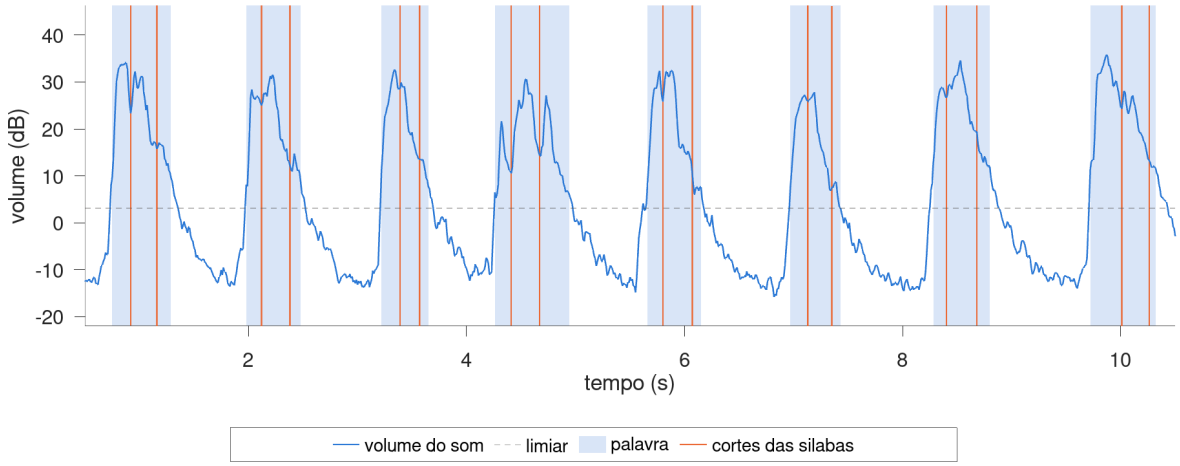


Figura 1 – Primeiros 10 s da gravação "direita": volume do som (azul), palavras encontradas (faixas claras), limiar (tracejado) e os cortes das sílabas (laranja).

2.2 Separar as sílabas

Dentro de uma palavra, o volume cai quando a boca fecha numa consoante: o /r/ de "direita", o /t/, o /k/ de "esquerda" e o /d/. Essas quedas são os **vales** da curva, e são neles que as sílabas são cortadas:

- **1º corte** (di|rei, es|quer): o vale mais fundo entre 15% e 50% da palavra;
- **2º corte** (rei|ta, quer|da): o vale mais fundo entre 45% e 95% da palavra, sempre depois do 1º. Aqui a curva usa só as frequências de 1 a 5 kHz, porque um zumbido grave de fundo "enchia" esse vale e escondia o corte.

O ponto exato foi ajustado ouvindo os trechos: no "direita" o corte vai no fundo do vale, e no "esquerda" no começo do vale, para o fechamento do /d/ ficar no "da". Só 9 dos 282 cortes não acharam vale; nesses, a palavra foi dividida em três partes iguais. A Figura 2 mostra o resultado em quatro palavras.

Ao longo do relatório, este método é chamado de **corte por energia**, porque corta nos vales da curva de energia (o volume). A alternativa mais simples seria o **corte em terços**: dividir cada palavra em três pedaços de mesma duração, sem olhar o som. Os dois foram comparados com o mesmo procedimento, e a seção 5.3

mostra por que o corte por energia foi o escolhido.

Também foram recortados **114 trechos de silêncio** de 300 ms, do meio das pausas entre as palavras. Eles formam a 7ª classe, para a rede saber quando nada está sendo dito.

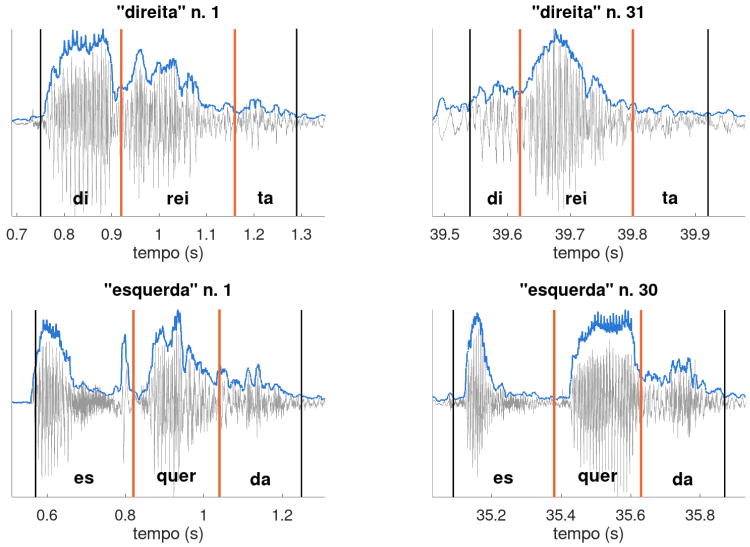


Figura 2 – Onda do som (cinza) de quatro palavras, com o contorno do volume (azul), o início e o fim da palavra (preto) e os dois cortes (laranja), que caem onde o volume "afina".

3 A REDE NEURAL

3.1 Janela deslizante

A rede não recebe a palavra nem a sílaba inteira. Ela recebe **pedaços de 150 ms** do áudio, chamados de **janelas**. A janela começa no início da palavra e vai sendo empurrada **25 ms por vez** até o fim. Como cada janela tem 150 ms e anda só 25 ms, uma janela se sobrepõe bastante à anterior:

```
janela 1:  [0 a 150 ms]
janela 2:      [25 a 175 ms]
janela 3:          [50 a 200 ms]   ...  e assim até o fim da palavra
```

Cada janela recebe como rótulo a sílaba onde cai o seu centro. Uma sílaba de 200 ms, por exemplo, gera cerca de 8 janelas. Isso foi feito por dois motivos:

- **A rede erra algumas janelas.** Como cada sílaba aparece em 6 a 10 janelas seguidas, a mesma sílaba é testada várias vezes antes de o programa decidir o que ela é. Um erro isolado não decide sozinho.
- **Mais exemplos de treino.** Em vez de 423 sílabas recortadas, a rede treina com 3.961 janelas.

O programa 2 (seção 4) usa exatamente a mesma janela de 150 ms andando 25 ms. Assim a rede é treinada com o mesmo tipo de entrada que vai receber na

hora de reconhecer as palavras.

3.2 O que entra na rede

Faixas de frequência. Cada janela de 150 ms passa pela FFT, que diz quanto som há em cada frequência. Usamos a faixa de **0 a 5 kHz**, dividida em **32 faixas de 156 Hz** cada (5000 ÷ 32). Cada faixa vira um número: a amplitude média do som naquela faixa. Assim, cada janela vira **32 números**. O limite de 5 kHz foi escolhido comparando o som das palavras com o do silêncio: a voz só se destaca do ruído até cerca de 4,2 kHz (99,9% da energia da voz fica abaixo disso), e acima de 5 kHz só entraria ruído.

Como começamos: sem contexto. No início, a rede recebia só esses 32 números da janela atual. É o que chamamos de **sem contexto**: a rede tenta dizer a sílaba olhando apenas aqueles 150 ms. O problema apareceu nas sílabas que têm a mesma vogal. O começo do "es" e o meio do "quer" são os dois um "e"; olhando só esse pedaço, o espectro é praticamente igual e a rede não tem como separá-los. Algo parecido acontecia entre o "di" e o "rei", que terminam no mesmo som de "i". Por isso, sem contexto, nenhuma rede passou de 80% de acerto nas sílabas, nem com 64 faixas nem com quatro camadas.

A solução: com contexto. O que diferencia o "e" do "es" do "e" do "quer" é o que vem antes e depois: o "s" no "es", o "qu" e o "r" no "quer". Como a janela deslizante (seção 3.1) já calcula uma janela a cada 25 ms, as janelas vizinhas já existem. Basta entregar à rede, junto com a janela atual, as janelas 50 ms e 100 ms antes e depois dela, uma ao lado da outra. Isso é o que chamamos de **com contexto**:

```
janelas:   -100 ms | -50 ms | atual | +50 ms | +100 ms
entrada:      32   +   32   +  32   +   32   +   32    = 160 números
```

A rede continua dando uma resposta por janela, mas agora "ouve" 350 ms ao redor do instante que está classificando, e por isso tem 160 entradas em vez de 32. A rede final usa **com contexto**; o ganho dessa mudança, o maior de todo o trabalho, aparece na seção 5.

Faixas, entradas e neurônios. São três números diferentes. As **faixas** dizem em quantos pedaços a frequência de uma janela é dividida (32). As **entradas** são quantos números a rede recebe de uma vez: 32 sem contexto, 160 com contexto (5 janelas × 32 faixas). Os **neurônios ocultos** são as camadas de 64 e 32 neurônios dentro da rede (seção 3.3), e não têm relação com as faixas. A rede final é, portanto, 160 entradas → 64 → 32 → 7 saídas.

Normalização. Antes de entrar na rede, os números de cada janela passam por uma normalização, para que falar mais alto ou mais baixo não mude a entrada. Foram testados três tipos (a comparação está na seção 5.1). Com três faixas de amplitude 10, 1 e 0,1, por exemplo:

- **max**: divide tudo pelo maior valor da janela, e as entradas ficam entre 0 e 1. O exemplo vira [1; 0,1; 0,01];
- **db**: faz o mesmo, mas em decibéis (escala logarítmica, de −60 a 0 dB, levada para 0 a 1). O exemplo vira [1; 0,67; 0,33]: as faixas fracas ganham muito mais peso;
- **zscore**: para cada faixa, subtrai a média e divide pelo desvio daquela faixa em todo o conjunto de treino. Não olha a janela, e sim o conjunto inteiro.

Divisão dos dados. A divisão foi feita **por palavra**: todas as janelas de uma mesma repetição vão para o mesmo conjunto, para nenhum pedaço das palavras de teste aparecer no treino. Ficaram 60% para treino (85 palavras), 20% para validação (27) e 20% para teste (29).

3.3 Rede e treino

A rede é uma MLP **160 → 64 → 32 → 7**, com uma saída por classe; a classe reconhecida é a saída de maior valor. O treino é a retropropagação do erro, como visto em aula:

```
erro na saída:   e = y − d
delta da saída:  δ = e · y · (1 − y)            (derivada da sigmoide)
delta anterior:  δ_ant = (δ · Wᵀ) · a · (1 − a)
atualização:     v = 0,9·v − η·gradiente ;  W = W + v   (momento 0,9)
```

Tabela 1 – Parâmetros do treino

Parâmetro	Valor
Ativação	sigmoide
Taxa de aprendizado η	0,5
Momento	0,9
Lote	32 janelas por atualização dos pesos
Épocas	automático: para após 200 épocas sem melhora na validação (máximo de 800)

Épocas. Uma época é a rede ver todas as janelas de treino uma vez. O número de épocas não é fixo: ao fim de cada época, mede-se o erro na validação e guarda-se a rede com o menor erro até ali (parada antecipada). Se o erro não melhora por um certo número de épocas seguidas (a **paciência**), o treino para e fica valendo a rede guardada. A paciência começou em 80 épocas. Ela foi aumentada para **200** para ver se a rede estava parando cedo, presa num mínimo local: algumas redes só acharam a melhor época depois da 300ª, mas o acerto não mudou de

patamar. Na rede final, a melhor época ficou entre 142 e 220.

4 PROGRAMA 2: RECONHECIMENTO DAS PALAVRAS

O programa 2 passa a janela pelo áudio e, a cada 25 ms, pergunta à rede qual é a sílaba. Como uma sílaba dura de 150 a 250 ms, ela aparece em várias janelas seguidas:

```
sil sil di di di di rei rei rei rei rei rei ta ta ta ta sil
```

Uma **máquina de estados**, como pede o enunciado, lê essa sequência: espera "di" (ou "es"), depois "rei" (ou "quer"), depois "ta" (ou "da"), e só então reconhece a palavra. Sílaba fora da ordem faz a palavra ser abandonada; silêncio no meio é tolerado por até 0,3 s.

4.1 Tolerância de 2 janelas

Olhando as palavras que o programa 2 errou, apareceu um padrão: a rede acerta a sílaba na maioria das janelas, mas às vezes erra **uma ou duas janelas soltas** no meio de uma palavra falada certo. Como a máquina de estados abandona a palavra na primeira sílaba fora da ordem, esse erro isolado derrubava a palavra inteira (Figura 3).

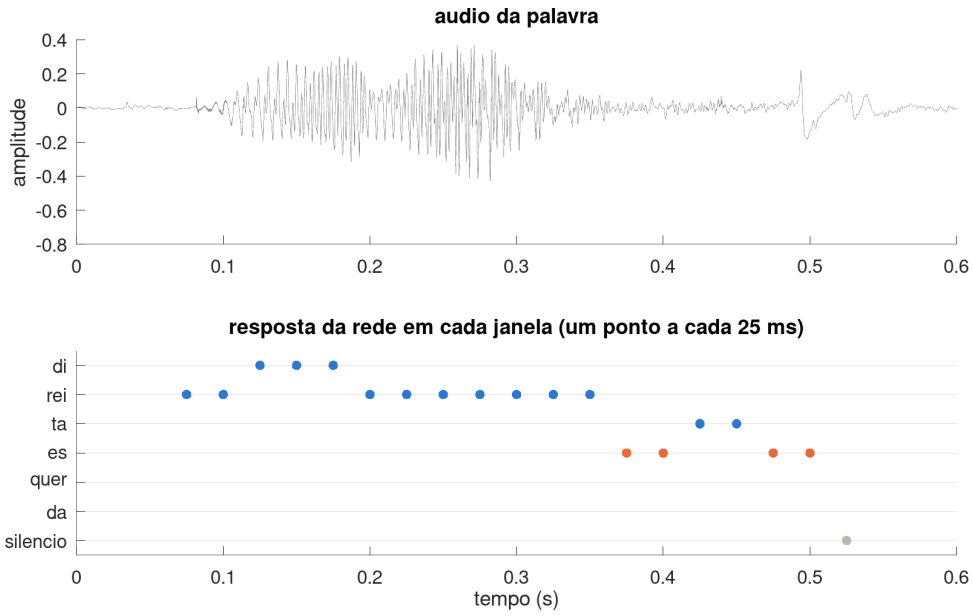


Figura 3 – Palavra de teste "direita": em cima o áudio, embaixo a resposta da rede em cada janela. Entre o "rei" e o "ta", duas janelas saíram como "es" (laranja). Sem tolerância, elas derrubam a palavra.

Por isso o programa passou a **ignorar até 2 janelas seguidas fora da ordem** (50 ms) antes de abandonar a palavra. A ordem exigida pelo enunciado continua a mesma. Uma sílaba trocada de verdade ("di quer ta") continua reprovada, porque

uma sílaba falada ocupa de 6 a 10 janelas, muito mais que 2. O efeito da tolerância foi medido na validação cruzada (seção 5.2).

5 COMO A REDE FOI ESCOLHIDA

5.1 Etapas

Nos primeiros testes, trocar só a semente (os pesos iniciais sorteados) mudava o resultado em várias palavras. Por isso cada opção foi treinada **5 vezes**, e comparamos a média e o desvio. Tudo foi medido na validação; o teste ficou guardado para o final. O critério principal foi o número de **palavras** reconhecidas (o objetivo do trabalho). Em caso de empate, decidiu o acerto das sílabas, e depois a opção mais simples. Os testes foram feitos em etapas, cada uma usando o vencedor da anterior.

Ao todo, foram **255 redes treinadas em testes automatizados**: 110 nas etapas abaixo, 120 nas mesmas etapas com o corte em terços (seção 5.3), 20 na validação cruzada e 5 no treino final. Antes desse procedimento, foram feitos **mais de 200 treinos exploratórios**, que serviram para ajustar os cortes das sílabas e mostrar que o contexto era o que mais melhorava a rede.

Tabela 2 – Resultado de cada etapa (validação, média de 5 treinos; 27 palavras)

Etapa	Opção	Palavras	Sílabas
1. Entrada	**32 faixas, com contexto (160 entradas)**	**20,8**	**83,7%**
	32 faixas, sem contexto (32 entradas)	20,0	78,5%
	64 faixas, sem contexto (64 entradas)	19,8	78,0%
	64 faixas, com contexto (320 entradas)	16,6	78,6%
2. Normalização	db	20,8	83,7%
	max	**20,0**	**86,5%**
	zscore	2,2	53,8%
3. Camadas ocultas	[256 128 64 32]	23,6	85,3%
	[128 64 32]	23,2	85,5%
	[64 32]	**23,2**	**87,2%**
	[32]	22,6	86,7%
	[128 64]	22,4	87,2%
	[64]	20,0	86,5%
	[128]	17,8	83,6%
4. Ativação e taxa	**sigmoide, 0,5**	**23,2**	**87,2%**
	sigmoide, 0,3	23,2	87,1%
	ReLU, 0,003 / 0,01	23,2	85,7% / 85,6%
	ReLU, 0,03 / 0,1	22,6 / 22,2	86,9% / 86,4%
	sigmoide, 0,1 / 1,0	21,4 / 22,8	86,9% / 86,3%

- **Entrada:** o contexto ganhou 5 pontos nas sílabas. Com 64 faixas não houve ganho, e com contexto o treino ficou instável (2 dos 5 treinos falharam).
- **Normalização:** max e db empataram nas palavras, e a max foi melhor nas sílabas; o zscore falhou (detalhes abaixo).
- **Camadas:** as redes de 2 a 4 camadas empataram nas palavras. A [64 32] foi a melhor nas sílabas e tem 7 vezes menos pesos que a de 4 camadas.
- **Ativação e taxa:** cada ativação foi testada com 4 taxas. Empate nas palavras; a sigmoide ganhou nas sílabas. Com taxa baixa demais a rede leva até 800 épocas; com taxa alta demais ela acerta menos.

A **max** foi a escolhida. Ela empatou com o db nas palavras (20,0 contra 20,8, diferença menor que o desvio entre os treinos) e foi melhor nas sílabas (86,5% contra 83,7%): todos os 5 treinos da max ficaram acima de todos os 5 do db. O zscore falhou, pois em 4 dos 5 treinos não reconheceu nenhuma palavra. A explicação provável é que o db "levanta" as faixas fracas, onde está principalmente o ruído da sala, enquanto a max mantém em destaque as faixas fortes da vogal. Já o zscore normaliza pelo conjunto e não pela janela: o volume da fala continua influindo, e as faixas que quase não variam (só ruído) ficam grandes demais depois de divididas por um desvio pequeno.

5.2 Validação cruzada

Na primeira medida, a rede escolhida acertou 25 de 27 palavras na validação, mas só 19 de 29 no teste. Com tão poucas palavras, cada uma vale mais de 3 pontos, e o resultado depende muito de quais palavras caíram em cada conjunto. Para ter um número confiável, fizemos uma **validação cruzada**: as 112 palavras que não são de teste foram divididas em 5 partes, e a rede foi treinada 5 vezes, cada vez validando numa parte diferente e treinando nas outras 4. Assim, cada uma das 112 palavras foi reconhecida por uma rede que nunca a viu. Com isso comparamos também as alternativas que tinham ficado em dúvida:

Tabela 3 – Validação cruzada: palavras reconhecidas das 112 (programa 2 como no enunciado)

Variante	Palavras	Sílabas
Corte por energia, com contexto (escolhida)	**90 (80,4%)**	**87,1%**
Corte em terços, com contexto	91 (81,2%)	82,7%
Corte por energia, 2º corte do "direita" no começo do vale	85 (75,9%)	86,2%
Corte por energia, sem contexto	73 (65,2%)	76,8%

- O acerto real da rede é de cerca de **80%**. Os 19 de 29 do primeiro teste vieram de um conjunto pequeno que, por acaso, era difícil.
- **Sem contexto**, a rede perde 17 palavras e 10 pontos nas sílabas: o contexto é necessário.

- O ajuste do 2º corte feito ouvindo os áudios (fundo do vale) rendeu 5 palavras a mais.

A mesma validação cruzada mediu o efeito da tolerância de 2 janelas do programa 2 (seção 4.1):

Tabela 4 – Efeito da tolerância (validação cruzada, palavras reconhecidas das 112)

Variante	Sem tolerância	1 janela	2 janelas	3 janelas
Energia, com contexto (escolhida)	90 (80,4%)	96 (85,7%)	**102 (91,1%)**	102 (91,1%)
Terços, com contexto	91 (81,2%)	96 (85,7%)	99 (88,4%)	100 (89,3%)
Energia, sem contexto	73 (65,2%)	84 (75,0%)	88 (78,6%)	91 (81,2%)

Tolerar 2 janelas acrescentou 12 palavras à rede escolhida (80,4% → 91,1%); tolerar 3 não acrescentou nada. A tolerância também não substitui o contexto: sem contexto, mesmo com 3 janelas de tolerância, a rede fica no nível da rede com contexto sem tolerância.

5.3 Energia × terços

Uma alternativa mais simples seria cortar cada palavra em três partes iguais (terços). O problema é que as sílabas não têm a mesma duração: no "direita", o "di" dura em média 118 ms e o "rei" 235 ms. Com terços, parte do "rei" seria ensinada à rede como "di", e o fim do "rei" como "ta". Os dois cortes foram comparados com o mesmo procedimento, e cada um com a sua melhor rede. Nas palavras eles empatam (90 contra 91, Tabela 3), mas a energia acerta 4,4 pontos a mais nas sílabas, com o maior ganho no "quer" (87% contra 71%). Com a tolerância da seção 4.1, a energia passa a reconhecer 3 palavras a mais (Tabela 4). Por isso o projeto usa o corte por energia.

6 RESULTADO FINAL

A configuração final foi treinada 5 vezes, e a rede com mais palavras na validação foi a escolhida. Só depois disso as 29 palavras de teste foram usadas, uma única vez.

Tabela 5 – Resultado no teste

Medida	Resultado
Palavras isoladas	**24 de 29 (82,8%)**: direita 12/14, esquerda 12/15, nenhuma trocada
Média dos 5 treinos	24,2 de 29 (83,4%); todos entre 24 e 25 palavras
Fala contínua	**27 de 29 (93,1%)**: 0 trocadas, 0 falsos alarmes
Janelas	treino 95,6% / validação 89,6% / teste 85,5%

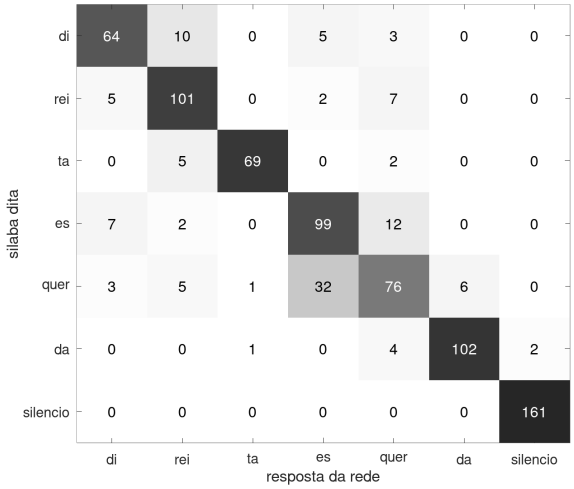


Figura 4 – Matriz de confusão das janelas de teste (linha: sílaba dita; coluna: resposta da rede).

O erro mais comum é "quer" respondido como "es" (32 janelas), duas sílabas vizinhas com a mesma vogal. Como esses erros aparecem em janelas soltas, a máquina de estados com tolerância não os transforma em palavras trocadas.

7 CONCLUSÃO

O objetivo do trabalho foi atingido: uma MLP pequena, treinada só com as sílabas, permitiu reconhecer as palavras inteiras com a máquina de estados pedida no enunciado. No teste final, **82,8% das palavras isoladas e 93,1% da fala contínua foram reconhecidas**, e o sistema **nunca confundiu DIREITA com ESQUERDA**: quando erra, ele deixa de reconhecer a palavra, mas não troca uma pela outra.

Os principais achados foram:

- **O contexto foi o maior ganho do trabalho.** Olhando só 150 ms, a rede não separa sílabas com a mesma vogal, como "es" e "quer". Com as janelas vizinhas na entrada, o acerto das sílabas subiu cerca de 5 pontos e a rede passou a reconhecer 17 palavras a mais na validação cruzada.
- **Rede maior não é rede melhor.** Redes de 2, 3 e 4 camadas empataram nas palavras, e a de duas camadas ([64 32]) foi a melhor nas sílabas, com 7 vezes menos pesos que a de quatro. A ReLU também não superou a sigmoide. Com 7 classes e cerca de 2.400 exemplos de treino, o limite estava na entrada, e não na rede.
- **Cortar onde o som realmente muda funciona melhor.** O corte nos vales de energia ensinou a rede com rótulos mais corretos do que a divisão em terços: as palavras empataram, mas as sílabas foram 4,4 pontos melhores, e com a

tolerância a energia reconheceu 3 palavras a mais.

- **Erros isolados da rede não precisam derrubar a palavra.** Ignorar até 2 janelas soltas fora da ordem (50 ms) acrescentou 12 palavras na validação cruzada, sem aceitar sílabas trocadas de verdade.
- **Com poucos dados, um único teste engana.** Trocar só os pesos iniciais mudava o resultado em várias palavras, e o primeiro teste (19 de 29) indicava um desempenho bem pior que o real (cerca de 80%). Repetir cada teste com 5 sementes e usar a validação cruzada foi o que permitiu escolher cada parâmetro com segurança.

A Tabela 6 resume cada decisão e o dado que a justificou.

Tabela 6 – Resumo das decisões

Decisão	**Escolha**	**Por quê**
Corte das sílabas	vales de energia	+4,4 pontos nas sílabas e +3 palavras sobre os terços
Frequências	0 a 5 kHz, 32 faixas	a voz vai até ~4,2 kHz; 64 faixas não ganharam
Contexto	±100 ms (160 entradas)	+5 pontos nas sílabas; +17 palavras
Normalização	max	empate nas palavras, melhor nas sílabas
Camadas	[64 32]	empate nas palavras, melhor nas sílabas, menor
Ativação e taxa	sigmoide, 0,5	empate nas palavras, melhor nas sílabas
Programa 2	tolerância de 2 janelas	+12 palavras na validação cruzada

A principal limitação que resta é a separação entre **"es" e "quer"**, que têm a mesma vogal e a fronteira menos nítida: é a troca mais comum na matriz de confusão (32 janelas). Como próximos passos, o sistema poderia ser testado com gravações de outras pessoas e com mais repetições, para medir o quanto ele generaliza além das gravações usadas no treino.

APÊNDICE – ARQUIVOS DO PROJETO

O projeto roda com um único comando, **rodar_projeto**, no MATLAB ou no Octave; no Windows, também com dois cliques em **rodar_projeto.bat**. As instruções completas estão no arquivo COMO_RODAR.txt.

Tabela 7 – Arquivos do projeto

Arquivo	**O que faz**
segmentar_audios.m	corta as gravações em palavras, sílabas e silêncios
extrair_entradas.m	transforma cada trecho de áudio no vetor de entrada da rede
mlp.m	a rede: criar, propagar, treinar (retropropagação) e classificar
entrada.m	monta a entrada: FFT em faixas, janelas vizinhas e normalização
treinar_mlp.m	treina a rede final e mede o teste
programa2_reconhecer.m	programa 2: reconhece as palavras com a máquina de estados
experimentos.m	testes usados para escolher cada parâmetro da rede